Липецкий государственный технический университет

Факультет автоматизации и информатики

Кафедра автоматизированных систем управления

ЛАБОРАТОРНАЯ РАБОТА №3

по дисциплине «Прикладные интеллектуальные системы и экспертные системы»

Классификация текстовых данных

Студент Коровайцева А.В.

Группа М-ИАП-23-1

Руководитель Кургасов В.В.

Доцент

Липецк 2023 г.

Цель работы

Получить практические навыки решения задачи классификации текстовых данных в среде Jupiter Notebook. Научиться проводить предварительную обработку текстовых данных, настраивать параметры методов классификации и обучать модели, оценивать точность полученных моделей.

Задание кафедры

1) Загрузить выборки по варианту из лабораторной работы №2.

2) Используя GridSearchCV произвести предварительную обработку данных и настройку методов классификации в соответствие с заданием, вывести оптимальные значения параметров и результаты классификации модели (полнота, точность, f1-мера и аккуратности) с данными параметрами. Настройку проводить как на данных со стеммингом, так и на данных, на которых стемминг не применялся.

3) По каждому пункту работы занести в отчет программный код и результат вывода.

4) Оформить сравнительную таблицу с результатами классификации различными методами с разными настройками. Сделать выводы о наиболее подходящем методе классификации ваших данных с указанием параметров метода и описанием предварительной обработки данных.

Вариант №8

Классы 5, 16, 20 (comp.sys.mac.hardware, 'soc.religion.christian', 'talk.religion.misc')

Методы SVM, DT и LR

Метод опорных векторов (SVM):

• функция потерь (параметр loss: ‘hinge’, ‘squared_hinge’),

• регуляризация (параметр penalty: ‘L1’, ‘L2’)

Обратить внимание, что разные виды регуляризации работают с разными функциями потерь.

Дерево решений (DT):

• критерий (параметр criterion: ‘gini’, ‘entropy’),

• глубина дерева (параметр max_depth от 1 до 5 с шагом 1, далее до 100 с шагом 20).

Логистическая регрессия (LR):

• метод нахождения экстремума (параметр solver: ‘newton-cg’, ‘lbfgs’, ‘sag’, ‘liblinear’),

• регуляризация (параметр penalty: ‘L1’, ‘L2’)

Обратить внимание, что разные виды регуляризации работают с разными методами нахождения экстремума.

Ход работы

Загрузим обучающую и тестовую выборку в соответствии с вариантом. Код для загрузки данных представлен на рисунке 1.

```
categories = ['comp.sys.mac.hardware', 'soc.religion.christian', 'talk.religion.misc']
remove = ('headers', 'footers', 'quotes')

twenty_train_full = fetch_20newsgroups(subset='train', categories=categories, shuffle=True, random_state=42, rem
twenty_test_full = fetch_20newsgroups(subset='test', categories=categories, shuffle=True, random_state=42, remov
```

Рисунок 1 – Код для загрузки данных из лабораторной работы №2

Зададим параметры, которые будем варьировать, чтобы найти наиболее оптимальные. Параметры для каждого из методов представлены на рисунке 2.

```
stop_words = [None, 'english']
max_features_values = [100, 500, 1000, 5000, 10000]
use_idf = [True, False]
```

```
dt_first = range(1, 5, 1)
dt_second = range(5, 100, 20)

decision_tree_max_depth = [*dt_first, *dt_second]
```

```
parameters_svm = {
    'vect__max_features': max_features_values,
    'vect__stop_words': stop_words,
    'tfidf__use_idf': use_idf,
}

parameters_dt = {
    'vect__max_features': max_features_values,
    'vect__stop_words': stop_words,
    'tfidf__use_idf': use_idf,
    'clf__criterion': ('gini', 'entropy'),
    'clf__max_depth': decision_tree_max_depth,
}

parameters_lr = {
    'vect__max_features': max_features_values,
    'vect__stop_words': stop_words,
    'tfidf__use_idf': use_idf,
    'clf__solver': ['newton-cg', 'lbfgs', 'sag', 'liblinear'],
    'clf__penalty': ['l2']
}

parameters_lr_l1 = {
    'vect__max_features': max_features_values,
    'vect__stop_words': stop_words,
    'tfidf__use_idf': use_idf,
    'clf__solver': ['liblinear'],
    'clf__penalty': ['l1'],
}
```

Рисунок 2 – Параметры для нахождения оптимальных значений классификации

Проведем классификацию методами SVM, DT и LR (и LR_L1). Код всех методов представлен в приложении А.

После проведения обучения моделей на обучающем наборе данных рассчитаем характеристики качества классификации по каждому методу.

Качество модели метода опорных векторов для данных без применения стемминга и оптимальные для неё параметры представлены на рисунке 3.

```
Метод опорных векторов (SVM) без стемминга

                        precision    recall  f1-score   support

  comp.sys.mac.hardware       0.86      0.98      0.92       385
soc.religion.christian       0.74      0.88      0.80       398
    talk.religion.misc       0.86      0.41      0.56       251

              accuracy                           0.80      1034
             macro avg       0.82      0.76      0.76      1034
          weighted avg       0.81      0.80      0.79      1034

{'tfidf__use_idf': True, 'vect__max_features': 5000, 'vect__stop_words': None}
```

Рисунок 3 – Качество модели метода опорных векторов для данных без применения стемминга и оптимальные для неё параметры

Качество модели метода опорных векторов для данных с применением стемминга и оптимальные для неё параметры представлены на рисунке 4.

```
Метод опорных векторов (SVM) со стеммингом

                        precision    recall  f1-score   support

  comp.sys.mac.hardware       0.88      0.92      0.90       385
soc.religion.christian       0.77      0.71      0.74       398
    talk.religion.misc       0.57      0.60      0.59       251

              accuracy                           0.76      1034
             macro avg       0.74      0.74      0.74      1034
          weighted avg       0.76      0.76      0.76      1034

{'tfidf__use_idf': True, 'vect__max_features': 10000, 'vect__stop_words': 'english'}
```

Рисунок 4 – Качество модели метода опорных векторов для данных с применением стемминга и оптимальные для неё параметры

Качество модели дерева решений для данных без применения стемминга и оптимальные для неё параметры представлены на рисунке 5.

```
Дерево решений (DT) без стемминга

                        precision    recall  f1-score   support

 comp.sys.mac.hardware       0.86      0.71      0.78       385
soc.religion.christian       0.66      0.63      0.64       398
    talk.religion.misc       0.36      0.49      0.42       251

              accuracy                           0.62      1034
             macro avg       0.63      0.61      0.61      1034
          weighted avg       0.66      0.62      0.64      1034

{'clf__criterion': 'gini', 'clf__max_depth': 65, 'tfidf__use_idf': False, 'vect__max_features': 5000, 'vect__stop_w
ords': 'english'}
```

Рисунок 5 – Качество модели дерева решений для данных без применения стемминга и оптимальные для неё параметры

Качество модели дерева решений для данных с применением стемминга и оптимальные для неё параметры представлены на рисунке 6.

```
Дерево решений (DT) со стеммингом

                        precision    recall  f1-score   support

 comp.sys.mac.hardware       0.84      0.62      0.71       385
soc.religion.christian       0.67      0.63      0.65       398
    talk.religion.misc       0.34      0.51      0.41       251

              accuracy                           0.60      1034
             macro avg       0.62      0.59      0.59      1034
          weighted avg       0.65      0.60      0.61      1034

{'clf__criterion': 'gini', 'clf__max_depth': 45, 'tfidf__use_idf': False, 'vect__max_features': 10000, 'vect__stop_
words': 'english'}
```

Рисунок 6 – Качество модели дерева решений для данных с применением стемминга и оптимальные для неё параметры

Качество модели логистической регрессии для данных без применения стемминга и оптимальные для неё параметры представлены на рисунке 7.

```
Логистическая регрессия (LR) без стемминга

                        precision    recall  f1-score   support

 comp.sys.mac.hardware       0.88      0.98      0.93       385
soc.religion.christian       0.73      0.89      0.80       398
    talk.religion.misc       0.80      0.39      0.52       251

              accuracy                           0.80      1034
             macro avg       0.80      0.75      0.75      1034
          weighted avg       0.80      0.80      0.78      1034

{'clf__penalty': 'l2', 'clf__solver': 'newton-cg', 'tfidf__use_idf': True, 'vect__max_features': 10000, 'vect__stop
_words': 'english'}
```

Рисунок 7 – Качество модели логистической регрессии для данных без применения стемминга и оптимальные для неё параметры

Качество модели логистической регрессии L1 для данных без применения стемминга и оптимальные для неё параметры представлены на рисунке 8.

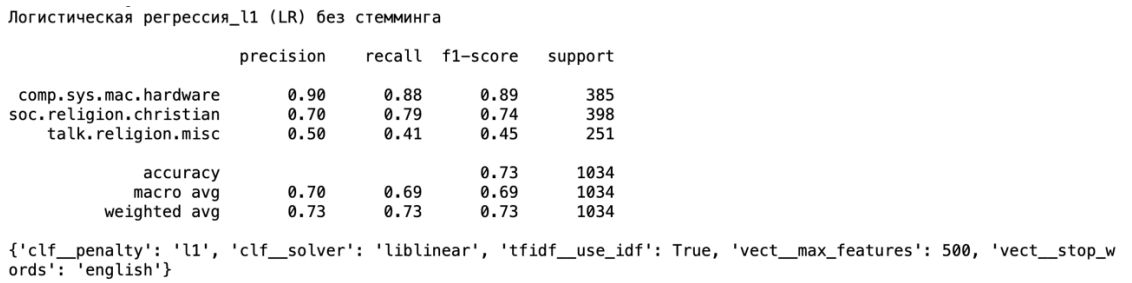

Логистическая регрессия_l1 (LR) без стемминга

	precision	recall	f1-score	support
comp.sys.mac.hardware	0.90	0.88	0.89	385
soc.religion.christian	0.70	0.79	0.74	398
talk.religion.misc	0.50	0.41	0.45	251
accuracy			0.73	1034
macro avg	0.70	0.69	0.69	1034
weighted avg	0.73	0.73	0.73	1034

{'clf__penalty': 'l1', 'clf__solver': 'liblinear', 'tfidf__use_idf': True, 'vect__max_features': 500, 'vect__stop_words': 'english'}

Рисунок 8 – Качество модели логистической регрессии L1 для данных без применения стемминга и оптимальные для неё параметры

Качество модели логистической регрессии для данных с применением стемминга и оптимальные для неё параметры представлены на рисунке 9.

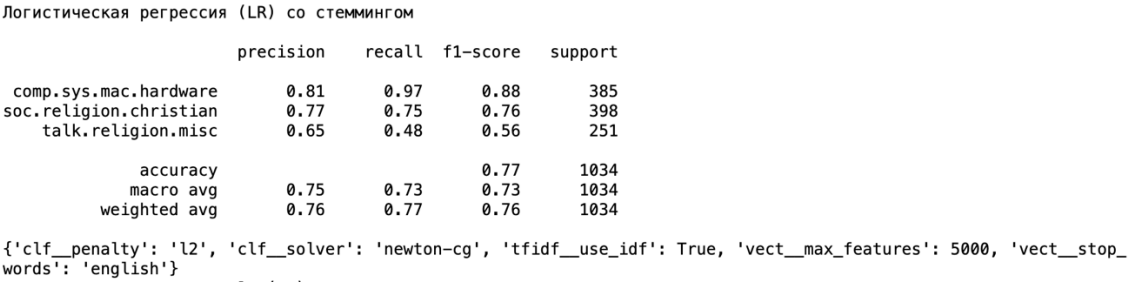

Логистическая регрессия (LR) со стеммингом

	precision	recall	f1-score	support
comp.sys.mac.hardware	0.81	0.97	0.88	385
soc.religion.christian	0.77	0.75	0.76	398
talk.religion.misc	0.65	0.48	0.56	251
accuracy			0.77	1034
macro avg	0.75	0.73	0.73	1034
weighted avg	0.76	0.77	0.76	1034

{'clf__penalty': 'l2', 'clf__solver': 'newton-cg', 'tfidf__use_idf': True, 'vect__max_features': 5000, 'vect__stop_words': 'english'}

Рисунок 9 – Качество модели логистической регрессии для данных с применением стемминга и оптимальные для неё параметры

Качество модели логистической регрессии L1 для данных с применением стемминга и оптимальные для неё параметры представлены на рисунке 10.

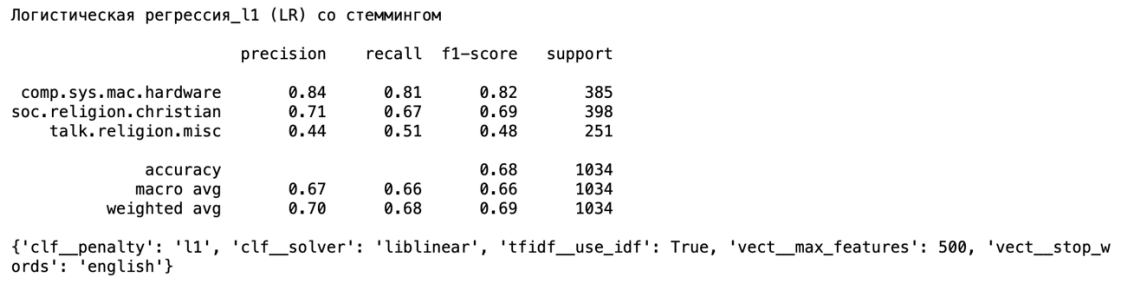

Логистическая регрессия_l1 (LR) со стеммингом

	precision	recall	f1-score	support
comp.sys.mac.hardware	0.84	0.81	0.82	385
soc.religion.christian	0.71	0.67	0.69	398
talk.religion.misc	0.44	0.51	0.48	251
accuracy			0.68	1034
macro avg	0.67	0.66	0.66	1034
weighted avg	0.70	0.68	0.69	1034

{'clf__penalty': 'l1', 'clf__solver': 'liblinear', 'tfidf__use_idf': True, 'vect__max_features': 500, 'vect__stop_words': 'english'}

Рисунок 10 – Качество модели логистической регрессии L1 для данных с применением стемминга и оптимальные для неё параметры

Вывод

В ходе выполнения данной лабораторной работы мною были получены практические навыки решения задачи классификации текстовых данных в среде Jupiter Notebook.

Также я научилась проводить предварительную обработку текстовых данных, настраивать параметры методов классификации и обучать модели, оценивать точность полученных моделей.

Мною были применены следующие методы: случайного леса (RF), логистической регрессии (LR) и метод опорных векторов (SVM).

Наилучшей точностью классификации для данного набора данных обладают модели метода опорных векторов и логистической регрессии без применения стемминга. Их точность составляет 80%. Параметры для данных моделей представлены соответственно на рисунках 3 и 7.

Приложение А

Исходный код

```
#!/usr/bin/env python
# coding: utf-8

# # Лабораторная работа №3
# ### Выгрузка данных из ЛР №2 (вариант №8)
# ### ('comp.sys.mac.hardware', 'soc.religion.christian',
'talk.religion.misc')

# In[2]:


import warnings
from sklearn.datasets import fetch_20newsgroups
warnings.simplefilter(action='ignore', category=FutureWarning)


# In[3]:


categories = ['comp.sys.mac.hardware', 'soc.religion.christian',
'talk.religion.misc']
remove = ('headers', 'footers', 'quotes')

twenty_train_full = fetch_20newsgroups(subset='train', categories=categories,
shuffle=True, random_state=42, remove=remove)
twenty_test_full = fetch_20newsgroups(subset='test', categories=categories,
shuffle=True, random_state=42, remove=remove)


# ### Применение стемминга

# In[27]:


import nltk
from nltk import word_tokenize
from nltk.stem import *

nltk.download('punkt')


# In[5]:


def stemming(data):
    porter_stemmer = PorterStemmer()
    stem = []
    for text in data:
        nltk_tokens = word_tokenize(text)
        line = ''.join([' ' + porter_stemmer.stem(word) for word in
nltk_tokens])
        stem.append(line)
    return stem


# In[6]:


stem_train = stemming(twenty_train_full.data)
stem_test = stemming(twenty_test_full.data)
```

```
# ### Задание
# ### Вариант №8
# ### Методы: [SVM, DT, LR]

# In[7]:


from sklearn.svm import SVC
from sklearn.tree import DecisionTreeClassifier
from sklearn.linear_model import LogisticRegression


# In[8]:


stop_words = [None, 'english']
max_features_values = [100, 500, 1000, 5000, 10000]
use_idf = [True, False]


# In[9]:


dt_first = range(1, 5, 1)
dt_second = range(5, 100, 20)

decision_tree_max_depth = [*dt_first, *dt_second]


# In[10]:


parameters_svm = {
    'vect__max_features': max_features_values,
    'vect__stop_words': stop_words,
    'tfidf__use_idf': use_idf,
}

parameters_dt = {
    'vect__max_features': max_features_values,
    'vect__stop_words': stop_words,
    'tfidf__use_idf': use_idf,
    'clf__criterion': ('gini', 'entropy'),
    'clf__max_depth': decision_tree_max_depth,
}

parameters_lr = {
    'vect__max_features': max_features_values,
    'vect__stop_words': stop_words,
    'tfidf__use_idf': use_idf,
    'clf__solver': ['newton-cg', 'lbfgs', 'sag', 'liblinear'],
    'clf__penalty': ['l2']
}

parameters_lr_l1 = {
    'vect__max_features': max_features_values,
    'vect__stop_words': stop_words,
    'tfidf__use_idf': use_idf,
    'clf__solver': ['liblinear'],
    'clf__penalty': ['l1'],
}
```

```
# In[11]:


from sklearn.model_selection import GridSearchCV
from sklearn.pipeline import Pipeline
from sklearn.feature_extraction.text import CountVectorizer, TfidfTransformer


# ### Метод опорных векторов (SVM)

# #### Без использования стемминга

# In[12]:


text_clf_svm = Pipeline([('vect', CountVectorizer()),
                         ('tfidf', TfidfTransformer()),
                         ('clf', SVC())])
gscv_svm = GridSearchCV(text_clf_svm, param_grid=parameters_svm, n_jobs=-1)
gscv_svm.fit(twenty_train_full.data, twenty_train_full.target)


# #### С использованием стемминга

# In[13]:


text_clf_svm_stem = Pipeline([('vect', CountVectorizer()),
                              ('tfidf', TfidfTransformer()),
                              ('clf', SVC(kernel='linear', C=1.0))])
gscv_svm_stem = GridSearchCV(text_clf_svm_stem, param_grid=parameters_svm,
n_jobs=-1)
gscv_svm_stem.fit(stem_train, twenty_train_full.target)


# ### Дерево решений (DT)

# #### Без использования стемминга

# In[14]:


text_clf_dt = Pipeline([('vect', CountVectorizer()),
                        ('tfidf', TfidfTransformer()),
                        ('clf', DecisionTreeClassifier())])
gscv_dt = GridSearchCV(text_clf_dt, param_grid=parameters_dt, n_jobs=-1)
gscv_dt.fit(twenty_train_full.data, twenty_train_full.target)


# #### С использованием стема

# In[15]:


text_clf_dt_stem = Pipeline([('vect', CountVectorizer()),
                             ('tfidf', TfidfTransformer()),
                             ('clf', DecisionTreeClassifier())])
gscv_dt_stem = GridSearchCV(text_clf_dt_stem, param_grid=parameters_dt,
n_jobs=-1)
gscv_dt_stem.fit(stem_train, twenty_train_full.target)


# ### Логистическая регрессия (LR)
```

```
# #### Без использования стемминга

# In[16]:


text_clf_lr = Pipeline([('vect', CountVectorizer()),
                        ('tfidf', TfidfTransformer()),
                        ('clf', LogisticRegression())])
gscv_lr = GridSearchCV(text_clf_lr, param_grid=parameters_lr, n_jobs=-1)
gscv_lr.fit(twenty_train_full.data, twenty_train_full.target)


text_clf_lr_l1 = Pipeline([('vect', CountVectorizer()),
                        ('tfidf', TfidfTransformer()),
                        ('clf', LogisticRegression())])
gscv_lr_l1 = GridSearchCV(text_clf_lr_l1, param_grid=parameters_lr_l1,
n_jobs=-1)
gscv_lr_l1.fit(twenty_train_full.data, twenty_train_full.target)


# #### С использованием стемминга

# In[17]:


text_clf_lr_stem = Pipeline([('vect', CountVectorizer()),
                             ('tfidf', TfidfTransformer()),
                             ('clf', LogisticRegression())])
gscv_lr_stem = GridSearchCV(text_clf_lr_stem, param_grid=parameters_lr,
n_jobs=-1)
gscv_lr_stem.fit(stem_train, twenty_train_full.target)


text_clf_lr_l1_stem = Pipeline([('vect', CountVectorizer()),
                             ('tfidf', TfidfTransformer()),
                             ('clf', LogisticRegression())])
gscv_lr_l1_stem = GridSearchCV(text_clf_lr_l1_stem,
param_grid=parameters_lr_l1, n_jobs=-1)
gscv_lr_l1_stem.fit(stem_train, twenty_train_full.target)


# ### Вывод полученных результатов анализа

# In[18]:


from sklearn.metrics import classification_report


# In[19]:


predicted_svm = gscv_svm.predict(twenty_test_full.data)
print('Метод опорных векторов (SVM) без стемминга\n')
print(classification_report(twenty_test_full.target, predicted_svm,
target_names=categories))
print(gscv_svm.best_params_)


# In[20]:


predicted_svm_stem = gscv_svm_stem.predict(twenty_test_full.data)
```

```
print('Метод опорных векторов (SVM) со стеммингом\n')
print(classification_report(twenty_test_full.target, predicted_svm_stem,
target_names=categories))
print(gscv_svm_stem.best_params_)


# In[21]:


predicted_dt = gscv_dt.predict(twenty_test_full.data)
print('Дерево решений (DT) без стемминга\n')
print(classification_report(twenty_test_full.target, predicted_dt,
target_names=categories))
print(gscv_dt.best_params_)


# In[22]:


predicted_dt_stem = gscv_dt_stem.predict(twenty_test_full.data)
print('Дерево решений (DT) со стеммингом\n')
print(classification_report(twenty_test_full.target, predicted_dt_stem,
target_names=categories))
print(gscv_dt_stem.best_params_)


# In[23]:


predicted_lr = gscv_lr.predict(twenty_test_full.data)
print('Логистическая регрессия (LR) без стемминга\n')
print(classification_report(twenty_test_full.target, predicted_lr,
target_names=categories))
print(gscv_lr.best_params_)

predicted_lr_l1 = gscv_lr_l1.predict(twenty_test_full.data)
print('Логистическая регрессия_l1 (LR) без стемминга\n')
print(classification_report(twenty_test_full.target, predicted_lr_l1,
target_names=categories))
print(gscv_lr_l1.best_params_)


# In[24]:


predicted_lr_stem = gscv_lr_stem.predict(twenty_test_full.data)
print('Логистическая регрессия (LR) со стеммингом\n')
print(classification_report(twenty_test_full.target, predicted_lr_stem,
target_names=categories))
print(gscv_lr_stem.best_params_)

predicted_lr_l1_stem = gscv_lr_l1_stem.predict(twenty_test_full.data)
print('Логистическая регрессия_l1 (LR) со стеммингом\n')
print(classification_report(twenty_test_full.target, predicted_lr_l1_stem,
target_names=categories))
print(gscv_lr_l1_stem.best_params_)


# ### Сравнительная таблица

# In[25]:


import pandas as pd
```

```
# In[26]:


writer = pd.ExcelWriter('result.xlsx', engine='openpyxl')

# Метод опорных векторов (SVM) без стемминга
df1 = pd.DataFrame(classification_report(predicted_svm,
twenty_test_full.target, output_dict=True))

# Метод опорных векторов (SVM) со стеммингом
df2 = pd.DataFrame(classification_report(predicted_svm_stem,
twenty_test_full.target, output_dict=True))

# Дерево решений (DT) без стемминга
df3 = pd.DataFrame(classification_report(predicted_dt,
twenty_test_full.target, output_dict=True))

# Дерево решений (DT) со стеммингом
df4 = pd.DataFrame(classification_report(predicted_dt_stem,
twenty_test_full.target, output_dict=True))

# Логистическая регрессия (LR) без стемминга
df5 = pd.DataFrame(classification_report(predicted_lr,
twenty_test_full.target, output_dict=True))

# Логистическая регрессия_l1 (LR) без стемминга
df6 = pd.DataFrame(classification_report(predicted_lr_l1,
twenty_test_full.target, output_dict=True))

# Логистическая регрессия (LR) со стеммингом
df7 = pd.DataFrame(classification_report(predicted_lr_stem,
twenty_test_full.target, output_dict=True))

# Логистическая регрессия_l1 (LR) со стеммингом
df8 = pd.DataFrame(classification_report(predicted_lr_l1_stem,
twenty_test_full.target, output_dict=True))

df1.to_excel(writer, sheet_name='SVM без стемминга')
df2.to_excel(writer, sheet_name='SVM со стеммингом')

df3.to_excel(writer, sheet_name='DT без стемминга')
df4.to_excel(writer, sheet_name='DT со стеммингом')

df5.to_excel(writer, sheet_name='LR без стемминга')
df6.to_excel(writer, sheet_name='LR_l1 без стемминга')

df7.to_excel(writer, sheet_name='LR со стеммингом')
df8.to_excel(writer, sheet_name='LR_l1 со стеммингом')

writer.close()
```